

Informe Técnico

Proyecto de Analítica de Clientes

Asignatura: SCY 1101 Programación para la Ciencia de Datos

Estudiantes:

- Javiera Olivares
- Adriano Contreras
- Patricio Maldonado

Docente:

- Jazna Meza

Fecha De Entrega: 08 / 04 / 2026

Índice

1.Introducción

2.Análisis Exploratorio Inicial

- 2.1. Estadísticas Descriptivas
- 2.2. Visualizaciones
- 2.3. Caracterización del Dataset

3.Metodología de Transformación

- 3.1. Técnicas de Limpieza
- 3.2. Imputación de Valores Faltantes
- 3.3. Ingeniería de Características
- 3.4. Justificación de Decisiones

4.Resultados y Validación

- 4.1. Evidencia de Limpieza y Transformación
- 4.2. Validación de Integridad
- 4.3. Validación de Calidad

5.Conclusiones y Recomendaciones

- 5.1. Reflexión Final
- 5.2. Dificultades Encontradas

INTRODUCCIÓN

En este proyecto nos enfocaremos en lo que sería el abandono de clientes, para esto usaremos una base de datos lo cual nos entregaría una información de 20.400 usuarios.

Como objetivo prioritario fue agarrar todos esos datos y aplicar un procesos de pasos en los cuales consisten en una limpieza y un análisis completos. En esos procesos presentamos varios errores los cuales tuvimos que solucionar en el archivo, como por ejemplo datos repetidos y valores nulos, los cuales procedimos a crear variables nuevas(feature Engineering) lo cual nos ayude a entender mucho mejor por que los clientes dejan de usar un servicio o se van. Lo que queremos buscar con esto es que los datos ya estén listos para que un modelo pueda predecir qué cliente tiene más riesgo a irse o más bien dejar de usar un servicio por temas financieros y encontrar una solución predictiva para que no hayan más abandonos.

Análisis exploratorio inicial

2.1 Estadísticas Descriptivas.

Nuestro dataset original constaba de 20.400 registros y 23 variables, compuesto por datos demográficos, financieros y de comportamiento de clientes.

Al ejecutar el resumen estadístico inicial (`data.describe()`), se identificó una gran dispersión en las variables financieras, especialmente en la variable 'deuda_total', donde la media se veía fuertemente arrastrada por valores atípicos extremos


Asimismo, se detectó la presencia de valores nulos propagados en múltiples columnas, lo que justificó la necesidad de un preprocesamiento robusto.

```
data.describe()
```

	id_cliente	edad	ingreso_mensual	gasto_mensual	deuda_total
count	20000.000000	20000.000000	1.898900e+04	18934.000000	1.986300e+04
mean	10000.500000	48.514850	8.332492e+05	401056.132548	2.077900e+06
std	5773.647028	17.857932	4.275221e+05	148837.592880	1.040023e+06
min	1.000000	18.000000	3.441726e+03	527.066597	1.528946e+03
25%	5000.750000	33.000000	6.352788e+05	298222.887917	1.476661e+06
50%	10000.500000	48.000000	8.047533e+05	399466.390062	2.022973e+06
75%	15000.250000	64.000000	9.742520e+05	500814.525068	2.561024e+06
max	20000.000000	79.000000	7.560936e+06	954575.217321	1.777694e+07

2.2 Visualizaciones

Para comprender la distribución subyacente, se generaron histogramas y diagramas de caja (boxplots). El hallazgo más crítico fue el sesgo hacia la derecha en las variables monetarias.



2.3 Caracterización

Se determinó que el dataset contenía variables redundantes o que actuaban como identificadores únicos (id_cliente, nombre_cliente, fecha_registro), las cuales no aportan valor predictivo generalizable. El problema central de negocio se definió como una clasificación binaria, siendo la variable objetivo el abandono.

Metodología de transformación

3.1 Técnicas de Limpieza

Se aplicó un enfoque de limpieza secuencial:

1. **Eliminación de identificadores:** Se descartaron las columnas irrelevantes para el modelado y se priorizó la privacidad de los datos.
2. **Deduplicación:** Se eliminaron registros duplicados basándose en el id_cliente, lo que redujo el dataset a su tamaño real (~20.000 registros).

3.2. Imputación de Valores Faltantes

Para garantizar la consistencia estadística y la reproducibilidad, se construyó un Pipeline de Machine Learning utilizando scikit-learn.

Variables numéricas: Se trataron con SimpleImputer(strategy="median") para evitar que los promedios se vieran afectados por la asimetría de los datos financieros.

Variables categóricas: Se utilizó SimpleImputer(strategy="most_frequent") para rellenar los vacíos con la moda de cada segmento.

3.3. Ingeniería de Características

Para otorgar mayor contexto financiero al algoritmo predictivo, se creó una variable sintética clave: el ratio_deuda.

Fórmula: $\text{deuda_total} / (\text{ingreso_mensual} + 1)$.

Justificación: Se añadió una constante +1 en el denominador para prevenir errores matemáticos de división por cero en clientes sin ingresos registrados. Esta variable mide la solvencia relativa del cliente, siendo un predictor crucial del abandono.

3.4 Justificación de decisiones.

Se tomó la decisión arquitectónica de utilizar OrdinalEncoder (asignando un valor numérico único a cada categoría) en lugar de One-Hot Encoding. Esta medida fue vital para preservar la dimensionalidad del dataset (manteniendo 19 columnas), evitando la dispersión de datos (*curse of dimensionality*) y facilitando la interpretación directa para las áreas de negocio.

Conclusiones y Recomendaciones

5.1 Reflexión final y modelo predictivo

A través de este proceso de limpieza, Feature Engineering (creación del ratio_deuda) y análisis exploratorio. Hemos demostrado con evidencia estadística que el abandono de clientes está fuertemente impulsado por factores como la falta de interacción reciente (ultima_compra_dias) y el nivel de estrés financiero.

Para capitalizar estos descubrimientos y pasar de un análisis descriptivo a una solución proactiva, el siguiente paso lógico es la implementación de un Modelo Predictivo de Machine Learning.

El valor de implementar este modelo predictivo radica en:

Aprendizaje Histórico: El algoritmo utilizará esta base de datos limpia para detectar patrones ocultos y reglas complejas que preceden a la fuga de un usuario.

Scoring de Probabilidad: En lugar de adivinar, el modelo evaluará a los clientes activos y les asignará un porcentaje exacto de riesgo de abandono (del 0% al 100%).

Sistema de Alertas y Retención Temprana: Al clasificar a los clientes en riesgo Alto, Medio o Bajo, la empresa podrá automatizar campañas de retención (descuentos, llamadas, correos) enfocando su presupuesto de marketing exclusivamente en quienes están a punto de irse, salvando la relación antes de que el abandono ocurra.

En definitiva, el trabajo de preparación de datos realizado en este notebook nos proporciona la base sólida y necesaria para construir una herramienta tecnológica que no solo explica el pasado del negocio, sino que anticipa y mejora su futuro.